Mini-Projet Data Science

Statistiques, Régression et Tests Paramétriques

Présenté par : Khadija Ibisk

Contexte et Objectifs

Analyse Métier

Étude des indicateurs de performance (KPIs) d'une plateforme e-commerce : Visites, Ventes, Temps de réponse, Clics.

Objectifs

Appliquer les statistiques descriptives, l'estimation de lois, la régression linéaire et les tests paramétriques.

Méthodologie

Analyse réalisée sous Python avec les bibliothèques Pandas, Numpy, Matplotlib et Scipy.Stats.

Étape 1: Exploration des Données

- **Taille du dataset :** 500 observations réelles.
- **Qualité :** Aucune valeur manquante détectée.
- **Variables :** 4 variables quantitatives clés.

"Le jeu de données est complet et prêt pour une analyse statistique fiable des performances commerciales."

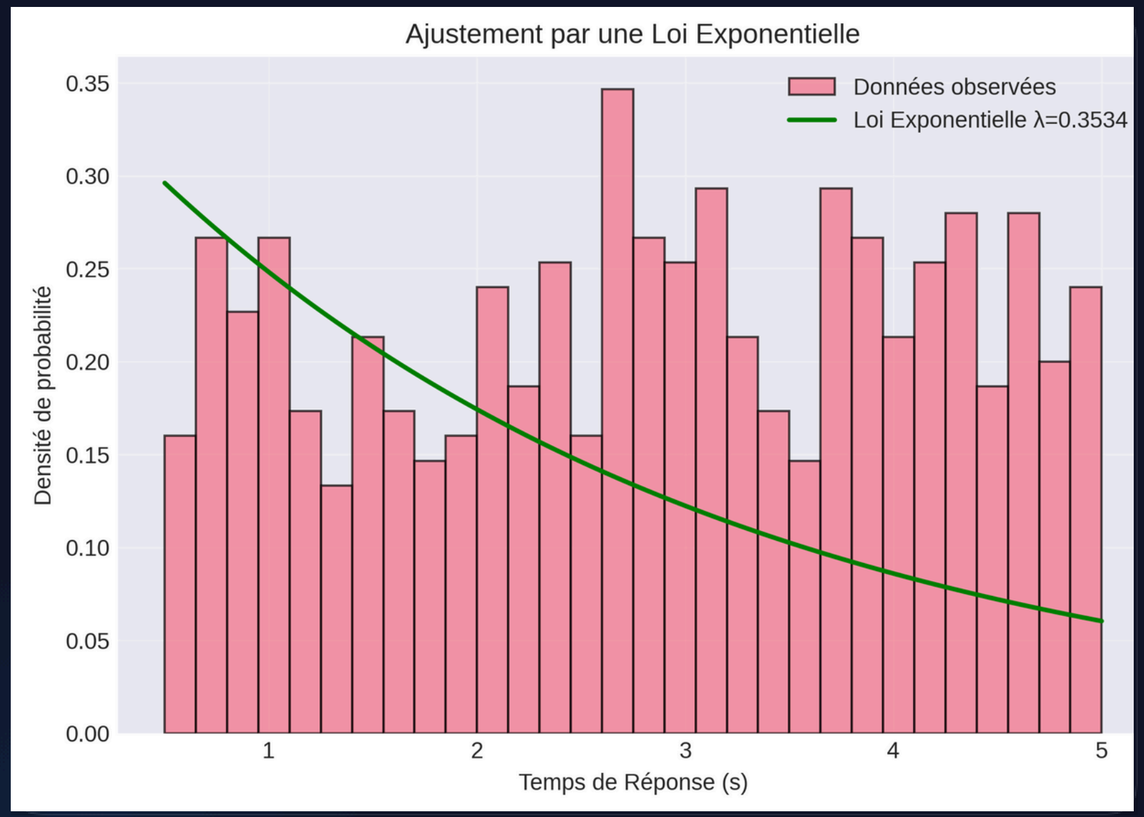
Variable	Type	Description
Visites	Quantitatif	Nombre de sessions sur le site
Ventes	Quantitatif	Conversions réalisées
Temps_Reponse	Quantitatif	Performance serveur (secondes)
Clic	Quantitatif	Engagement utilisateur

Étape 2: Statistiques Descriptives

Statistique	Visites	Ventes	Temps_Reponse	Clic
Moyenne (μ)	5126.90	245.57	2.83	25.18
Écart-type (σ)	2805.44	140.85	1.30	14.71
CV (%)	**54.72%**	**57.36%**	**45.77%**	**58.41%**
Minimum	104.00	10.00	0.50	0.00
Maximum	9988.00	497.00	5.00	50.00

Interprétation : Forte dispersion pour toutes les variables (CV > 45%), indiquant une grande hétérogénéité des comportements e-commerce.

Analyse Visuelle des Distributions



Insights Visuels

Histogrammes : Distributions étalées sans concentration marquée.

Boxplots : Présence de valeurs extrêmes pour le Temps de Réponse (pics d'activité).

ECDF : Progression régulière confirmant la nature continue des variables.

Étape 5: Tests de Normalité

Hypothèses

H0 : Les données suivent une loi normale

H1 : Rejet de la normalité

Décision : Rejet de H0

Toutes les p-values sont inférieures à 0.05.

Variable	Shapiro-Wilk	Conclusion
Visites	< 0.001	Non Normale
Ventes	< 0.001	Non Normale
Temps_Reponse	< 0.001	Non Normale
Clic	< 0.001	Non Normale

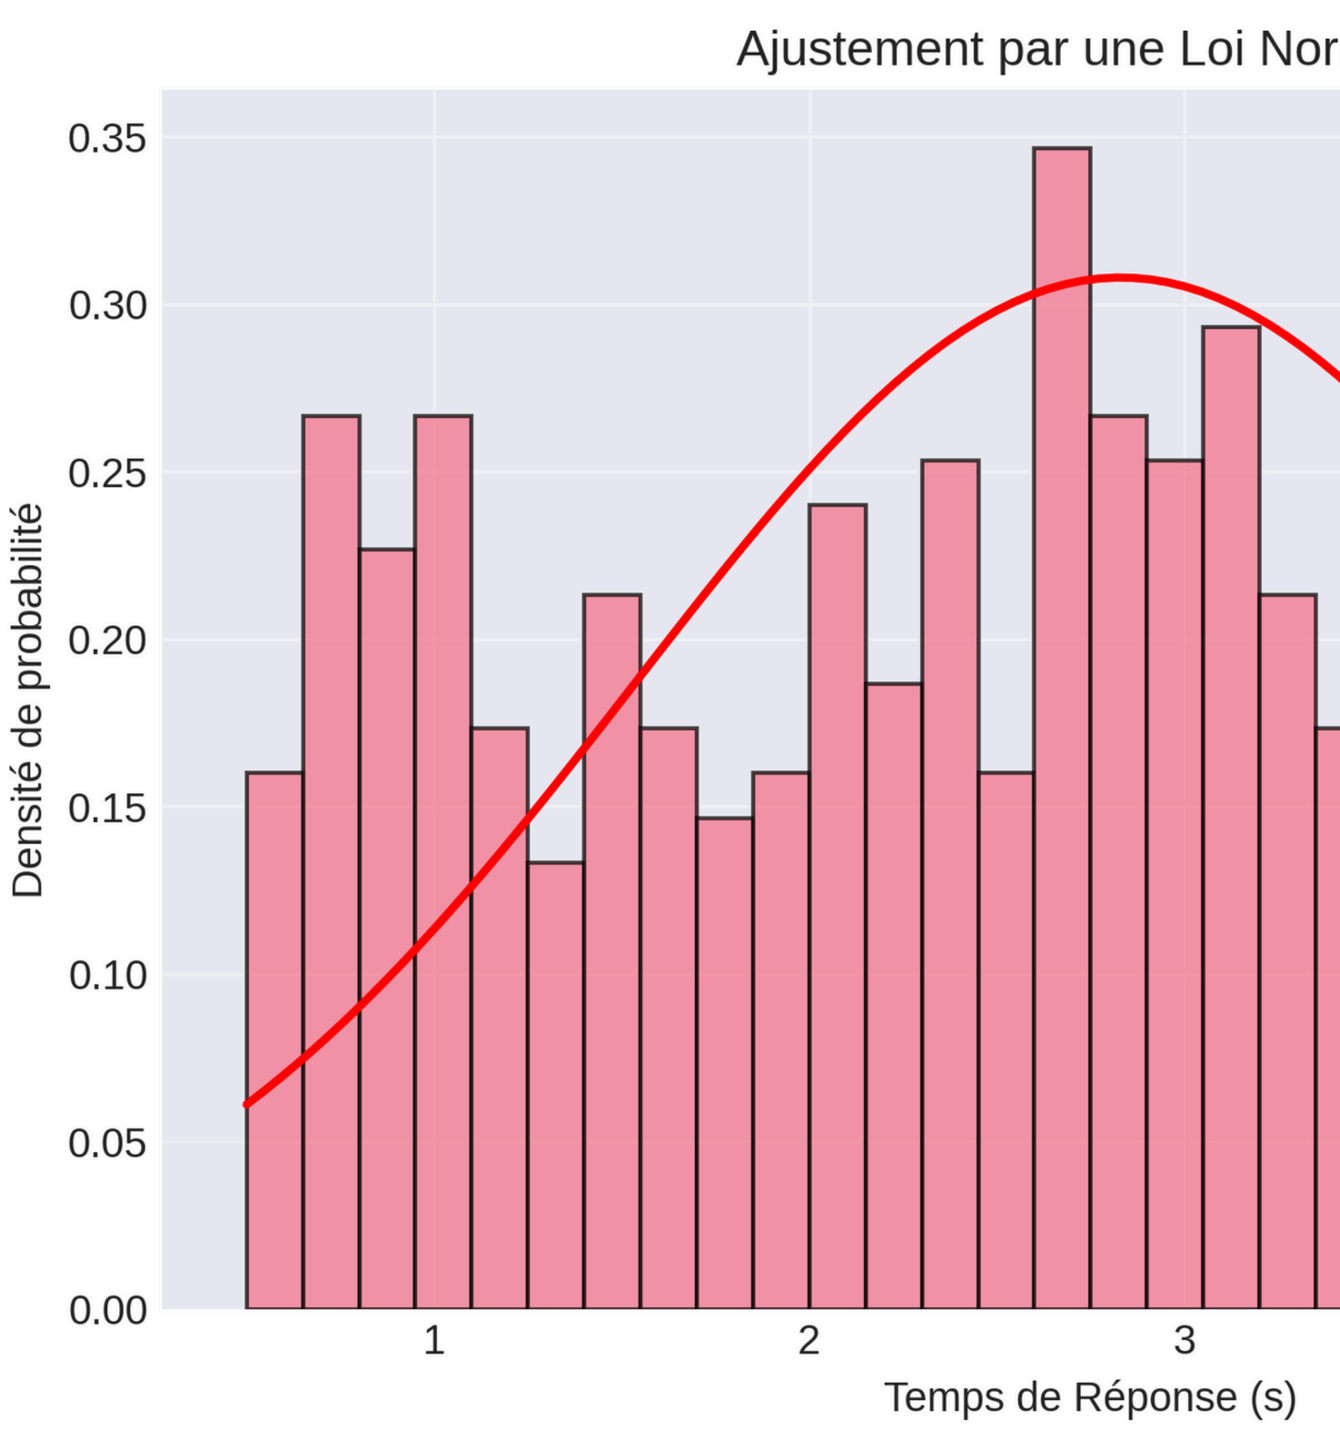
Estimation des Lois

Malgré le rejet de la normalité, nous estimons les paramètres pour modéliser le comportement du Temps de Réponse.

$$\hat{\lambda} = \frac{1}{\bar{X}} \approx 0.3534$$

Loi Normale : Approximée par $N(2.83, 1.68)$

Loi Exponentielle : $\lambda \approx 0.35$ (modélisation des temps d'attente serveur).



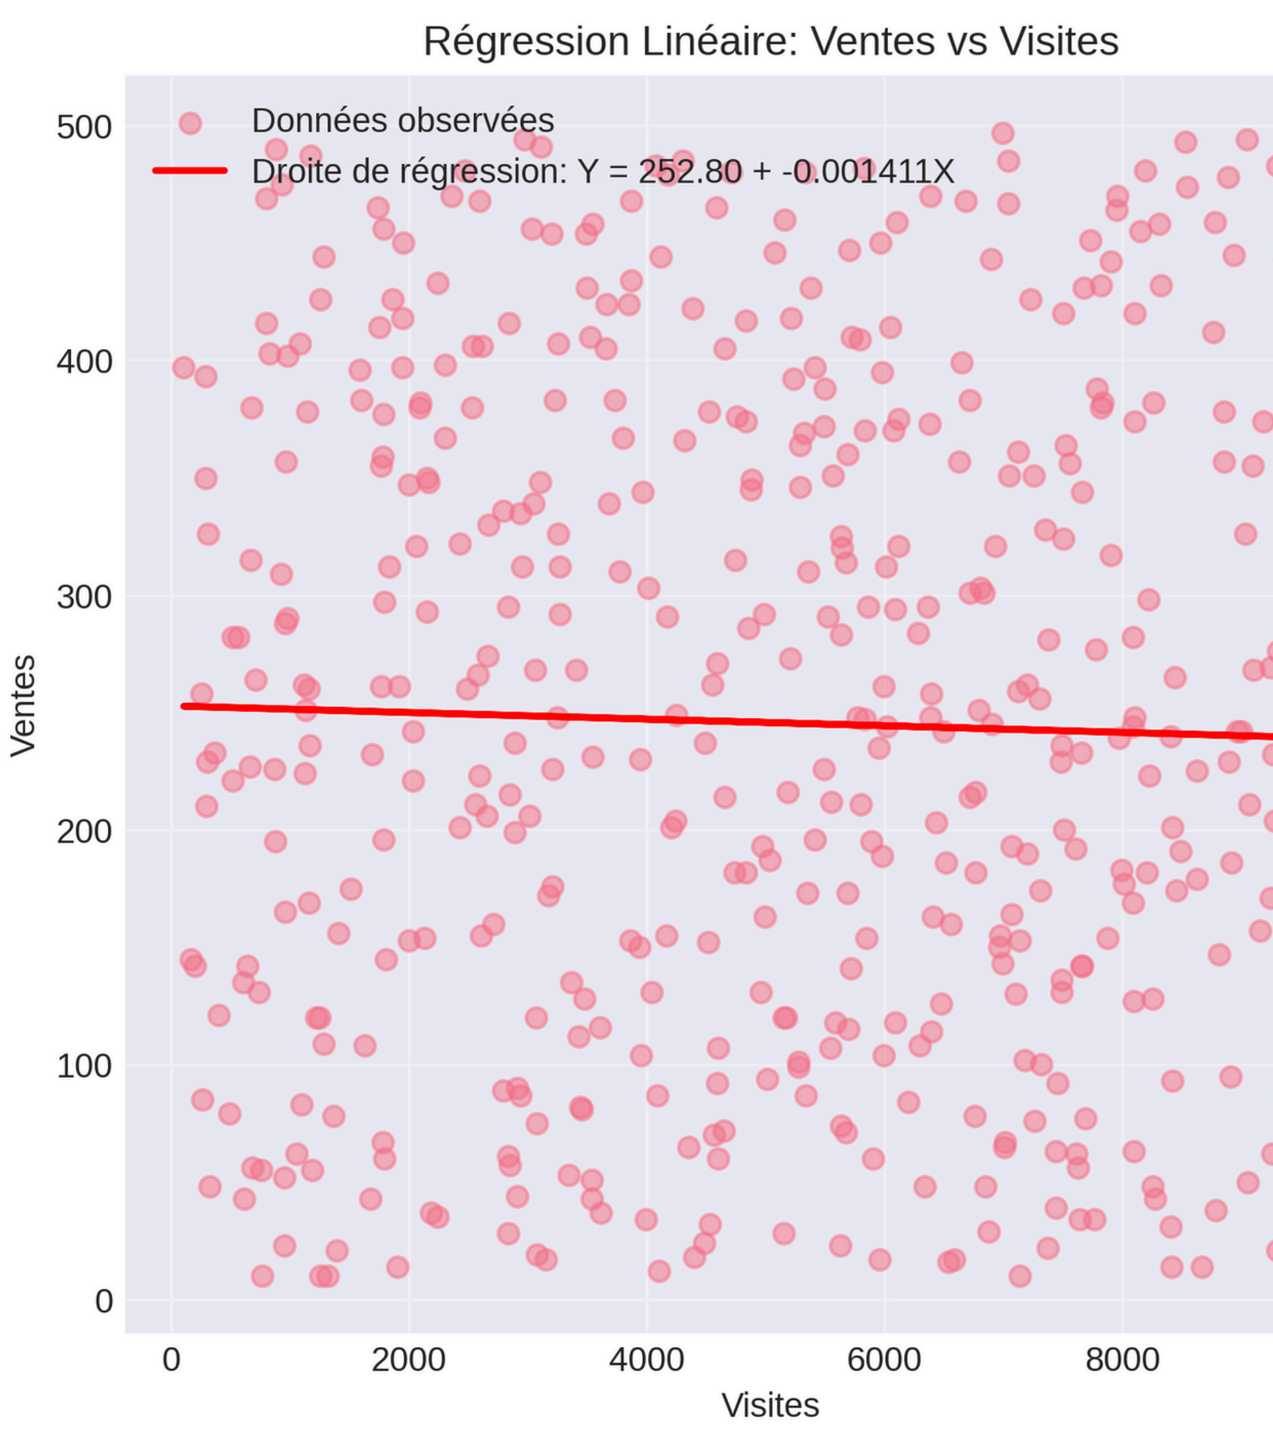
Régression Linéaire

Analyse de la relation entre les Visites (X) et les Ventes (Y).

$$\text{Ventes} = 252.80 - 0.001411 \times \text{Visites}$$

$R^2 = 0.08\%$

La relation est **très faible**. Les visites seules ne permettent pas de prédire les ventes.



Test de Student: Performance SLA

2830
MOYENNE (MS)

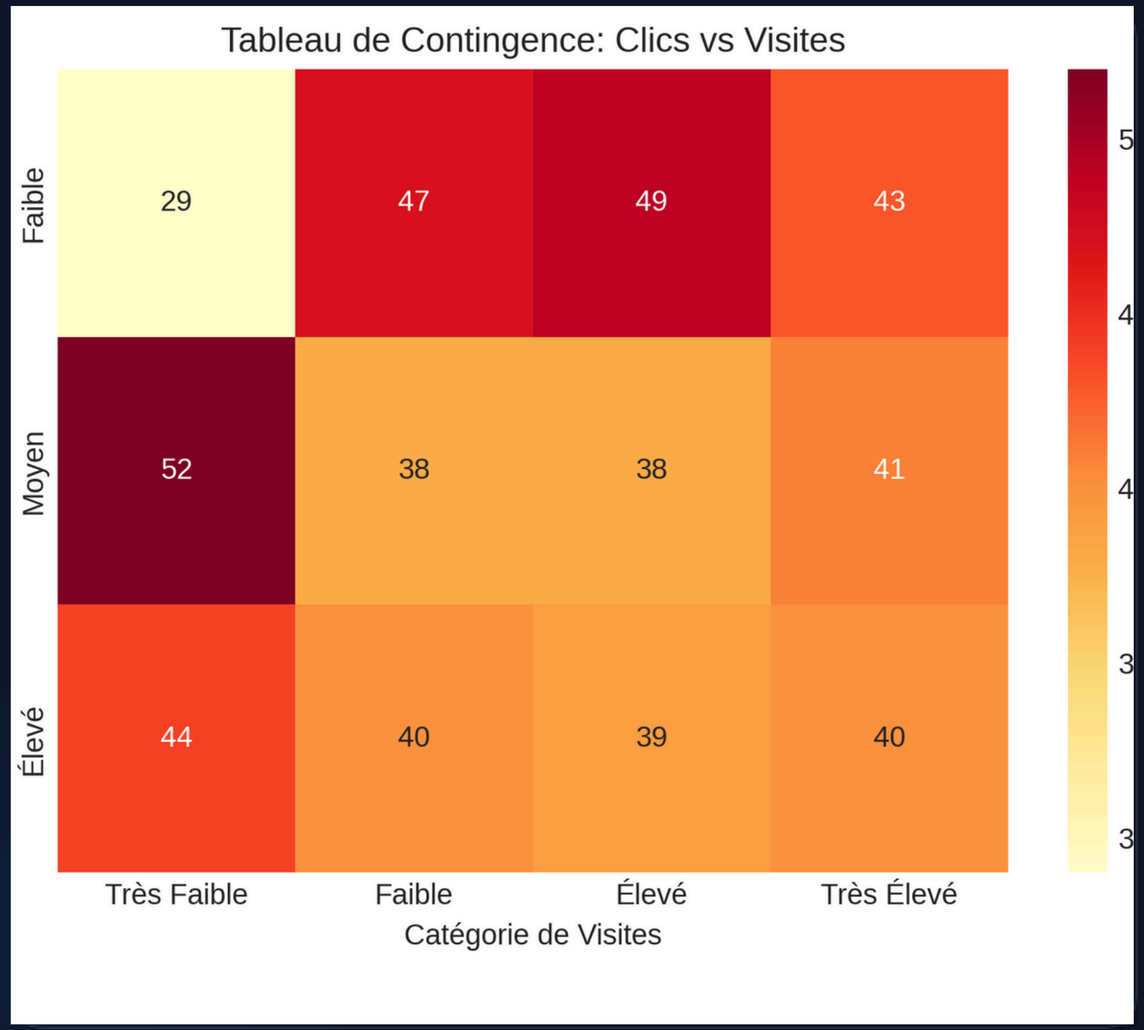
VS

150
CIBLE SLA (MS)

⚠ALERTE CRITIQUE

Le temps de réponse observé est **18 fois supérieur** à la limite contractuelle. Différence hautement significative ($p \approx 0$).

Étape 9: Test d'Indépendance (Khi-deux)



Clics vs Visites

p-value = 0.158 : Acceptation de H0.

Conclusion : Les variables sont indépendantes.

V de Cramer (0.096) : Association quasi nulle.

Le comportement d'engagement (Clics) ne dépend pas du volume d'affluence (Visites).

Synthèse et Recommandations

Technique

- Optimisation urgente du serveur.
- Analyse des goulots d'étranglement.

Business

- Améliorer la qualité du trafic.
- Analyser l'UX pour booster les ventes.

Analyse

- Modélisation multivariée.
- Monitoring en temps réel.

Merci de votre attention

Place aux questions et discussions

Projet présenté par : Khadija Ibisk

Tuteur : Morchadi Redouan